Laboratorio 7.
Regresión Logística

INTRODUCCIÓN:

La empresa **SmartStay Advisors** es una firma intermediaria que facilita la búsqueda y selección de propiedades en Airbnb para clientes corporativos y particulares.

El modelo operativo es el siguiente:

- El cliente proporciona requerimientos específicos (ciudad, presupuesto, tipo de propiedad, capacidad, duración de estancia).
- SmartStay analiza la oferta disponible y propone propiedades que optimicen precio, calidad y disponibilidad.
- Airbnb ofrece incentivos económicos a SmartStay cuando logra incrementar el nivel de ocupación de propiedades con bajo desempeño.

La empresa desea implementar modelos de minería de datos que le permitan:

1. Estimar precios competitivos.
2. Identificar propiedades con baja ocupación.
3. Comprender qué factores influyen en la ocupación y los ingresos.
4. Diseñar estrategias basadas en datos para aumentar la rentabilidad.

Conjunto de datos a utilizar

- listings.Rdata

Resultados esperados en esta Quinta Entrega de consultoría:

Se espera la entrega de un informe detallado donde incluya las explicaciones de los pasos que llevó a cabo y los resultados obtenidos en la generación y aplicación de los modelos. Recuerde que la investigación debe ser reproducible por lo que debe guardar el código que ha utilizado.

Notas:

- Se realizará en los mismos grupos.
- Cada individuo será evaluado de forma individual basado en sus aportes al trabajo grupal, por lo que deben versionar el código para poder revisar las contribuciones de cada uno.

ACTIVIDADES

1. Cree una variable dicotómica por cada una de las categorías de la variable respuesta categórica que creó en hojas anteriores. Debería tener 3 variables dicotómicas (valores 0 y 1) una que diga si la vivienda es cara o no, media o no, económica o no.
2. Use los mismos conjuntos de entrenamiento y prueba que utilizó en las hojas anteriores.
3. Elabore un modelo de regresión logística para conocer si el precio de una vivienda es **cara o no**, utilizando el conjunto de entrenamiento y explique los resultados a los que llega. El experimento debe ser reproducible por lo que debe fijar que los conjuntos de entrenamiento y prueba sean los mismos siempre que se ejecute el código. Use validación cruzada.
4. Analice el modelo. Determine si hay multicolinealidad en las variables, y cuáles son las que aportan al modelo, por su valor de significación. Haga un análisis de correlación de las variables del modelo y especifique si el modelo se adapta bien a los datos.
5. Utilice el modelo con el conjunto de prueba y determine la eficiencia del algoritmo para clasificar.
6. Explique si hay sobreajuste (overfitting) o no (recuerde usar para esto los errores del conjunto de prueba y de entrenamiento). Muestre las curvas de aprendizaje usando los errores de los conjuntos de entrenamiento y prueba.
7. Haga un tuneo del modelo para determinar los mejores parámetros, recuerde que los modelos de regresión logística se pueden regularizar como los de regresión lineal.
8. Haga un análisis de la eficiencia del algoritmo usando una matriz de confusión. Tenga en cuenta la efectividad, donde el algoritmo se equivocó más, donde se equivocó menos y la importancia que tienen los errores, el tiempo y la memoria consumida. Para esto último puede usar “profvis” si trabaja con R y “cProfile” en Python.
9. Determine cual de todos los modelos es mejor, puede usar AIC y BIC para esto, además de los parámetros de la matriz de confusión y los del profiler.
10. Haga un modelo de árbol de decisión, uno de Random Forest, uno de Naive Bayes y uno de KNN usando la misma variable respuesta y los mismos predictores (variables) que el mejor de los modelos de Regresión Logística. La diferencia a los que ya hizo en laboratorios anteriores es que ahora solo van a predecir si es cara o no.
11. Compare la eficiencia de los 3 modelos que creó en el punto anterior y el mejor de los de regresión logística ¿Cuál se demoró más en procesar?¿Cuál se equivocó más?¿Cuál se equivocó menos?¿por qué?
12. Como ahora las categorías cambiaron, elabore un análisis minucioso en donde pueda discutir qué modelo es mejor. Analícelo desde diferentes aristas: tiempo de entrenamiento, performance, precisión para una clase (cara) y otra (barata), etc. Apoye sus conclusiones con gráficas, tablas comparativas y/o cualquier otro elemento que el grupo considere importante.

EVALUACIÓN

Nota: Tiene que poderse comprobar su aporte al trabajo grupal a través de commits. Si no existen **al menos 3 commits con su aporte significativo** no va a tener nota de la hoja de trabajo. Utilice una herramienta que permita registrar los aportes de cada uno.

- **(20 puntos)** Análisis de los modelos generados. Verificar si están sobreajustados o no Recuerde explicar los razonamientos.
- **(20 puntos)** Análisis de las variables a incluir en los modelos. Pruebas de normalidad, correlación, etc. (Recuerde que las variables predictoras deberían ser las mismas para poder comparar)
- **(10 puntos)** Aplicación de los modelos al conjunto de prueba.
- **(20 puntos)** Matriz de confusión de cada modelo. Explicación de los resultados obtenidos
- **(10 puntos)** Tuneo de modelos, selección del mejor modelo.
- **(20 puntos)** Comparación entre sí de los modelos generados.

MATERIAL A ENTREGAR

- Archivo .rmd, .ipynb o Google docs con el informe con lo solicitado en las instrucciones
- Script de R o de Python que utilizó debidamente organizado y comentado (Si utilizó rmd debe añadir el html que se genera)
- Link de controlador de versiones utilizado.

FECHAS DE ENTREGA

- **AVANCE:** Puntos del 1 al 6 de la sección de actividades: viernes 17 de abril a las 17:20.
- **ENTREGA FINAL:** domingo 19 de abril a las 23:59